EU 개인정보 보호 주요 정책 및 동향

2026. VOL.11

KISA EU 개인정보보호 협력센터('26.7월)

EDPB 「생성형 AI 개발을 위한 웹 스크래핑」 가이드라인 주요 내용 및 시사점

주요내용 및 시사점

- EDPB는 7월 7일 생성형 AI 개발 과정의 웹 스크래핑에 관한 GDPR 준수 가이드라인(Guidelines 03/2026)을 발표하여, 웹 스크래핑이 GDPR상 적법성·투명성·책임성 요건을 충족하는 경우에 한해 허용될 수 있음을 전제로 데이터 최소화, 정당한 이익, 민감정보 처리 및 보안조치 기준을 구체화함

- 특히 웹 스크래핑 금지 신호(robots.txt, AI 관련 opt-out 신호 등) 준수, 민감정보 수집 방지, 정보주체 권리 보호, 데이터 출처 관리 및 개인정보 영향평가(DPIA) 등 데이터 수집·관리 전반에 걸친 책임성(Accountability) 강화를 요구함

- 이에 따라 생성형 AI 개발 및 데이터셋 재사용 기업은 웹 스크래핑 전략뿐 아니라 데이터 거버넌스, 데이터 출처 및 이력 관리, 개인정보 보호체계를 전반적으로 재정비할 필요가 있을 것으로 전망됨

1 웹 스크래핑에 관한 지침 및 GDPR 준수 기준

□ 개요 및 배경

○ EDPB는 GDPR 해석의 일관성을 확보하고 **생성형 AI 개발 과정에서 개인정보 처리의 적법성에 관한 명확한 준수 기준을 제시**하기 위해 해당 가이드라인을 채택

- EDPB는 생성형 AI 개발을 위한 웹 스크래핑 자체를 금지하는 것이 아니라, GDPR상 **적법성·투명성·비례성 원칙을 충족**하는 경우 허용될 수 있음을 전제로 **구체적인 준수 기준을 제시**

- 웹 스크래핑은 **생성형 AI 학습을 위한 대규모 데이터 확보 과정에서 위험*을 수반**하여 GDPR 위반 가능성이 높은 처리활동으로 평가됨

  * 개인정보의 비의도적 수집, 민감정보 포함 가능성, 데이터 최소화 원칙 충돌, 정보주체 권리 보장 등

- 가이드라인은 2026.10.30일까지 이해관계자의 의견을 수렴하는 공개 의견조회 절차를 거쳐 최종 확정될 예정

□ 가이드라인 적용 범위 및 핵심 GDPR 조항

○ **(적용 범위)** 본 가이드라인은 생성형 AI 개발 과정에서 웹 스크래핑을 활용하는 **개인정보 처리활동을 중심으로 적용**되며, **웹 스크래핑 과정에서 개인정보를 처리하는 경우 GDPR이 적용됨**

- 스크래핑을 직접 수행하지 않더라도 **스크래핑 된 데이터셋을 AI 학습 등에 활용하는 경우에도 GDPR상 의무가 적용**

- **(적용 대상)** ① 직접 웹 스크래핑을 수행하는 AI 개발자, ② 외부 업체에 스크래핑을 위탁하는 기업, ③ 스크래핑된 데이터셋을 재사용하는 기업 등이 포함되며,

- AI 개발 생태계에서 데이터셋 제공자, 파운데이션 모델 개발자 및 데이터

재사용 기업 등 데이터 공급망 전반의 참여자가 데이터 처리 목적과 수단에 따라 컨트롤러·공동 컨트롤러 또는 프로세서로 구분될 수 있으며 이에 따른 GDPR상 책임을 부담할 수 있음

○ **(핵심 조항)** 생성형 AI 개발 과정에서 웹 스크래핑이 야기하는 GDPR 준수와 관련된 주요 위험요인 및 각 조항별 적용 기준을 제시

< EDPB 가이드라인의 주요 GDPR 준수 기준 및 내용 >

조항/영역	EDPB 가이드라인 주요 내용
목적 제한	- AI 학습 목적은 구체적·특정해야 하며, 'AI 모델 개선'과 같은 포괄적 목적만으로는 목적 특정성 요건 충족 어려움 - 수집 데이터는 AI 학습 목적과 양립 불가능한 방식으로 재사용 불가
데이터 최소화	- **(스크래핑 전 단계)** 수집 기준·범위·대상 명확화, 필요하지 않은 데이터 필터링, 데이터 매핑 및 인벤토리 작업, 스크래핑 반대 웹사이트 제외*, 민감정보 포함 가능성이 높은 웹사이트 제외 * robots.txt, AI 관련 opt-out 신호(ai.txt 등), CAPTCHA 등 웹사이트의 스크래핑 제한 의사 표시를 존중하고 이를 우회하지 않아야 함 - **(스크래핑 중/이후 단계)** 식별가능한 개인정보 필터링·제거, 가능한 경우 합성데이터(synthetic data)로 대체, 익명화 또는 가명처리 * 단순한 식별자 제거만으로는 익명화로 인정되기 어려우며, 재식별 가능성을 고려한 실질적인 익명화 여부를 검토해야 함
정확성	- **신뢰 가능한 출처에서만 스크래핑 수행** - **타임스탬프 기록** - **AI 학습 전 데이터 검증(validation)** - 데이터셋 품질 관리 체계 구축
투명성	- 원칙적으로 정보 주체의 권리·자유·정당한 이익을 보호하기 위해 개별 통지 의무가 적용되며, 개별 통지가 불가능·과도한 부담일 경우 예외 가능 - 예외 적용 시에도 공개된 **개인정보 안내(privacy notice)* 필수** * 공지에는 데이터 출처·범주·법적 근거·수집 시점 등 포함

조항/영역	EDPB 가이드라인 주요 내용
정보주체 권리 보호	- 정보주체의 삭제권, 처리 제한권 및 처리 반대권이 실질적으로 보장될 수 있도록 데이터 출처 관리 및 권리 행사 절차를 마련해야 함
법적 근거	- 일반적으로 '**정당한 이익**'을 **법적 근거로 검토 가능** - 정당한 이익 요건(목적 정당성·필요성·정보주체의 권리에 대한 비례성) 엄격 적용
민감정보	- 원칙적으로 인종, 민족 출신, 정치적 의견, 건강, 성적 지향 등 특별 범주 개인정보의 처리 금지 - 민감정보 처리 시 적법한 근거와 예외 조항 적용 모두 필요하나, 예외는 매우 제한적이며, AI 학습 목적은 대부분 예외사유에 해당하기 어려움 - 민감정보의 의도적 수집은 원칙적으로 금지되며, 부수적·잔여적으로 수집된 경우에도 즉시 삭제, 필터링 및 모델 학습 배제 등 보호조치를 마련해야 함
보안 조치	- 악성 데이터 주입(poisoning) 위험, 데이터셋 오염·모델 재현(regurgitation) 가능성에 대응하여 데이터셋 검증, 악성 데이터 탐지, 스크래핑 도구 보안 강화, 데이터셋 접근 통제, 모델 재현 방지 기술 도입 필요
책임성	- 대규모 웹 스크래핑이 정보주체의 권리와 자유에 높은 위험을 초래할 가능성이 있는 경우 **GDPR 제35조에 따른 개인정보 영향평가(DPIA) 수행** - 처리 목적·데이터 출처·위험평가 및 기술적·관리적 보호조치 등을 문서화하여 책임성을 입증

2 가이드라인 주요 사례(case studies)

□ 투명성

○ 컨트롤러의 공개 공지를 통한 정보 제공

- AI 모델을 학습시키기 위해 AI 개발자가 20년간 축적된 방대한 양의 데이터를 수집, **정보주체에게 연락할 수 있는 수단이 없고 개별 통지가 사실상 불가능하거나 과도한 부담에 해당**

- 이에 따라 컨트롤러는 **필요한 정보를 웹사이트에 공개**하고, 정보주체가 직접 식별 가능한 웹페이지의 데이터를 수집 대상에서 제외하는 보호조치 적용

○ **폐쇄형 커뮤니티 스크래핑**

- 5천명 규모의 폐쇄형 커뮤니티의 지난 2년간 활동한 데이터를 수집한 경우, 정보주체를 직접 식별할 수 있으며 개별 통지가 가능하므로 예외 적용 불가, 공개 웹사이트가 아니므로 정당한 이익에 해당되지 않음

□ 법적 근거 및 보안 조치

○ **스크래핑 금지 신호**

- 자유롭게 접근할 수 있는 콘텐츠 공유 플랫폼이 사용자에게 콘텐츠가 스크래핑될 가능성을 명확히 알리고 웹 스크래핑을 금지하지 않을 경우, 정보주체는 제3자의 스크래핑 가능성을 합리적으로 예상 가능

- 반대로 robots.txt, AI 관련 opt-out 신호(ai.txt 등), CAPTCHA 등을 통해 웹 스크래핑을 금지한 경우, 정보주체는 제3자의 스크래핑을 합리적으로 예상하기 어려우며, 이는 정당한 이익 판단에 영향을 미침

○ **정당한 이익**

- 생성형 AI 개발을 위한 웹 스크래핑은 일반적으로 정당한 이익을 법적 근거로 검토할 수 있으나, **목적의 정당성, 처리의 필요성, 정보주체의 권리·이익과의 균형성(Balancing test) 등 GDPR상 요건을 모두 충족해야 함**

  * GDPR에서는 ▲목적의 정당성 (Purpose test), ▲처리의 필요성 (Necessity test), ▲이익 형량-비례성(Balancing test) 등 3단계를 통해 정당한 이익 여부를 판단

- 공개된 온라인 음성 녹음 자료를 대량으로 수집하면서 **데이터 보호 및 불법적·악의적 재사용 방지를 위한 보호조치를 마련하지 않은 경우, 정당한 이익을 법적 근거로 인정받기 어려움**

- 반면, 정보주체가 공개한 온라인 공개 출처의 데이터만을 활용하고 저작권 보호 콘텐츠를 제외하며, **필요한 보호조치*를 마련한 경우에는 정당한 이익을 법적 근거로 인정받을 가능성이 있음**

* 데이터 기억 및 재현 위험을 제한하는 기술적 조치, 문제적 콘텐츠 생성 가능성을 기술적·계약적 조치로 제한, 재식별이 가능한 경우 정보주체의 권리 행사 절차 마련, 데이터 출처를 표시한 공개된 프라이버시 정책 제공 등

□ 민감정보

○ GC and Others v. CNIL (C-136/17)

- EU 사법재판소(CJEU)는 검색엔진이 웹페이지를 색인하고 검색 결과를 제공하는 과정에서 특별범주 개인정보*를 처리하는 경우, 원칙적으로 GDPR의 특별범주 개인정보 처리 제한 규정이 적용된다고 판단

* **특별범주 개인정보**: 인종·민족 출신, 정치적 견해, 종교, 건강정보, 생체정보, 유전자정보, 성생활 또는 성적 지향 등 GDPR에서 원칙적으로 처리를 제한하는 민감한 개인정보

- 다만 검색엔진의 일반적인 색인 기능의 특수성과 운영자의 통제 범위를 고려하여, 해당 제한 규정은 운영자의 책임·권한·기술적 역량 범위 내에서 적용되야 한다고 판시

- 이에 따라 해당 판례는 검색엔진의 특수성을 고려하여 GDPR 제9조의 적용 범위와 운영자의 책임을 해석한 사례로 평가됨

○ EDPB 해석

- EDPB는 해당 판례가 생성형 AI 학습을 위한 웹 스크래핑 과정에서 특별범주 개인정보가 부수적·잔여적으로 수집되는 경우 참고될 수 있으나, 이는 예외적인 상황에 한정된다고 설명

- 특히 단순히 개인정보가 공개되어 있다는 이유만으로 특별범주 개인정보 처리가 허용되는 것은 아니며, GDPR 제9조의 예외요건을 충족하는 경우에만 제한적으로 허용될 수 있다고 명시

- **(예외 적용 조건)** 검색엔진 처리와 유사한 처리활동, 의도적 수집이

아닌 부수적·잔여적 수집, 사전 방지가 기술적으로 어려운 경우, 민감정보 확산 방지를 위한 보호조치*를 모두 갖춘 경우

* (수집 이전) 민감정보 탐지 필터 적용, 민감정보 포함 가능성이 높은 웹사이트 제외
* (수집 이후) 민감정보 즉시 삭제 및 정보주체 요청 시 삭제
* (AI 개발 단계) 민감정보 추출 방지, 프라이버시 공격 저항성 확보, 출력 필터 적용
* (운영 단계) 출력 모니터링, 민감정보 출력 시 즉시 대응 및 장기적 모델 언러닝 검토

3 의의 및 시사점

□ 기업에 대한 영향

○ EDPB 가이드라인은 생성형 AI 개발 과정에서 웹 스크래핑을 수행하거나 스크래핑된 데이터셋을 재사용하는 기업뿐 아니라, 데이터 공급망에 참여하는 다양한 사업자에게 영향을 미칠 것으로 전망

○ 특히 대규모 웹 데이터 수집 과정에서 민감정보가 포함될 가능성이 높은 만큼, **민감정보 탐지·제거 기술과 데이터 품질 관리 체계 구축에 따른 비용 증가가 예상**

○ 또한 웹 스크래핑 금지 신호(robots.txt, AI 관련 opt-out 신호 등)를 자동으로 준수하고, 폐쇄형 커뮤니티·회원제 서비스 등을 수집 대상에서 제외하는 등 **데이터 수집 전략 전반에 대한 재검토가 필요**

○ 개별 통지 의무가 면제되더라도 **개인정보 처리방침과 웹 스크래핑 관련 안내를 공개**하고, 데이터 출처 및 데이터셋 이력을 관리하는 등 데이터 거버넌스 체계 강화가 필요

○ 또한 대규모 웹 스크래핑이 고위험 개인정보 처리에 해당할 가능성이 있는 만큼, **DPIA 수행 여부를 사전에 검토**하고 **데이터 출처 관리, 삭제 요청 대응, 데이터셋 이력 관리** 등을 포함한 데이터 거버넌스 체계를 마련할 필요가 있음

○ 아울러 단순한 가명처리만으로 GDPR 적용이 배제되는 것은 아니므로, 재식별 가능성을 고려한 익명화 기준과 데이터 품질 관리 체계를 함께 구축할 필요

□ EU 규제 · 정책 체계에 대한 영향

○ 이번 가이드라인은 GDPR뿐 아니라 AI Act, Data Act 등 EU의 AI · 데이터 규제 체계와 연계하여 **AI 개발 과정의 데이터 거버넌스를 강화하려는 정책 흐름의 일환으로 평가됨**

- 특히 AI Act상 범용 AI(GPAI) 모델 제공자에게 요구되는 데이터 거버넌스 및 투명성 의무와 연계되어, 학습 데이터의 출처 관리와 개인정보 보호에 대한 요구 수준이 더욱 강화될 것으로 전망

○ 최근 ESRB 및 ESAs가 제기한 생성형 AI의 사이버 위험 우려와 맞물려, EDPB도 웹 스크래핑을 GDPR 위반 위험이 높은 개인정보 처리활동으로 보고, 보다 구체적인 준수 기준을 제시한 것으로 평가됨

○ 이에 따라 데이터 수집 단계에서의 규제 강화와 함께 데이터 품질 · 보안 · 투명성에 대한 요구 수준이 높아지고, **민감정보 처리 위험 관리 및 책임성(Accountability) 확보가 더욱 중요**해질 것임

○ 아울러 스크래핑 수행자뿐 아니라 AI 개발자, 데이터 브로커, 데이터셋 재사용 기업 등 데이터 공급망 전반으로 GDPR상 책임 범위가 확대되는 추세

- 이에 따라 기업은 데이터 거버넌스와 개인정보 컴플라이언스 체계를 전반적으로 강화할 필요가 있을 것으로 보임

4 참고자료

- https://www.edpb.europa.eu/system/files/2026-07/edpb_guidelines_2020603_webscraping_v1_en_0.pdf
- https://www.edpb.europa.eu/news/edpb-sheds-light-on-anonymisation-and-web-scraping-for-generative-ai-and-adopts-final-version_en
- https://eur-lex.europa.eu/legal-content/EN/TXT/PDF/?uri=CELEX:62017CJ0136_RES
- https://www.eba.europa.eu/publications-and-media/press-releases/eas-support-esrb-warning-systemic-cyber-risks-frontier-ai-models
- https://www.esrb.europa.eu/news/pr/date/2026/html/esrb.pr260707~4e1b68241a.en.html